

# <인공지능디지털헬스케어>

## Research Result Report

AI의료융합전공

### Contents

I. Object

II. Introduction

III. Materials

IV. Procedure

V. Data/Results

VI. Discussion

VII. Conclusion

# I. Object

**광용적맥파(Photoplethysmography, PPG)** 신호만을 활용하여 개인 식별과 연령대(20대 vs 50대) 분류 가능성을 검증하고, PPG 기반 생체신호가 개인 고유 특성 및 연령에 따른 생리적 차이를 반영하는지를 확인하는 것을 목표로 한다. 이를 위해 20대 2명과 50대 2명을 대상으로 검지 손가락 PPG 센서를 이용해 신호를 수집하였으며, 3일간 동일한 조건에서 세션당 5분씩 반복 측정하여 데이터셋을 구축하였다. 측정은 의자에 앉은 상태에서 손의 위치를 고정하고 안정된 휴식 상태를 유지하는 방식으로 수행하였다.

최종적으로, 수집된 PPG 파형을 입력으로 딥러닝 기반 분류 모델을 구축하여 개인별 데이터의 구분 가능성과 연령대 구분 성능을 평가하고, 웨어러블 환경에서의 간편한 개인 인증 및 혈관 노화(혈관 나이) 관련 지표로의 활용 가능성을 확인하는 것을 목표로 한다.

# II. Introduction

**생체인증**은 개인의 신체적·생리적 특성을 이용해 본인 여부를 확인하는 인증 방식으로, 분실이나 도난의 위험이 있는 기존 인증 수단을 보완하기 위한 대안으로 활용되어 왔다. 최근에는 금융 서비스, 정보 보안, 헬스케어 영역을 중심으로 적용 범위가 확장되고 있으며, 심장 박동과 연관된 생체신호(ECG, PPG)를 이용한 방식도 함께 주목받고 있다. 이 가운데 **PPG**는 말초 혈관에서의 혈액량 변화를 광학적으로 측정하여 맥파 형태의 신호를 획득하는 비침습적 방법이다. PPG 파형에는 혈관 구조, 혈류 반응, 심박 리듬과 같은 생리적 특성이 함께 반영되며, 개인마다 일정한 차이를 가질 수 있다. 이러한 특성은 단순한 생체 신호 측정을 넘어, 개인을 구분하거나 연령에 따른 생리적 차이를 반영하는 데 활용될 가능성을 가진다.

따라서, PPG 신호만을 이용해 개인을 구분할 수 있는지, 그리고 연령대 차이가 분류 가능한 형태로 나타나는지를 함께 살펴보았다. 단일 센서 기반의 PPG 신호가 개인 고유 특성과 연령대 차이를 반영할 수 있는지를 분석하고, 웨어러블 환경에서의 활용 가능성을 함께 검토하고자 한다.

# III. Materials

PPG 신호를 이용한 개인 식별 및 연령대 분류를 수행하기 위해, 임베디드 보드에서 측정 제어 및 데이터 출력 로직을 직접 구현하여 PPG 데이터를 수집하고, 수집된 텍스트 기반 PPG 시계열을 Python 환경에서 전처리한 뒤, 1D CNN 기반 딥러닝 모델로 학습 및 평가하는 파이프라인을 구성하였다. 임베디드 측정 로직은 Keypad 입력을 통해 측정 시작, 종료 및 초기화를 제어하도록 구현하였으며, 설정된 측정 구간 동안 PPG를 샘플링한 뒤 UART로 값을 전송하도록 설계하였다. 한 측정 세그먼트는 약 5분 30초(330초)로 고정하여, 파일 단위 데이터가 일정한 길이를 갖도록 하였다.

임베디드 보드로부터 전송된 PPG 데이터는 텍스트 파일(txt) 형태로 저장되었으며, Python 기반 분석 환경에서 전처리 및 딥러닝 모델 학습에 사용하였다. 전체 파이프라인은 텍스트 기반 PPG 시계열을 읽어들이고, 일정 길이의 구간으로 분할하여 학습 입력을 구성하고, 파일(세그먼트) 단위로 최종 클래스를 예측하는 구조로 설계하였다. 단일 샘플이나 매우 짧은 구간보다는, 일정 시간 동안 축적된 PPG 패턴이 개인 특성 및 연령대 차이를 보다 안정적으로 반영할 수 있다는 점을 고려하였다. 텍스트 파일은 한 줄 단위로 기록된 값에서 PPG 샘플

을 추출하여 1차원 시계열로 변환하였고, 파일 경로 및 폴더 구조를 이용해 개인 ID 또는 연령대 라벨을 일관되게 부여하였다.

전처리 단계에서는 원시 시계열을 그대로 모델에 입력하지 않고, baseline drift(저주파 추세 성분) 및 잡음 성분을 완화하기 위한 필터링을 먼저 적용한 뒤, 슬라이딩 윈도우 방식으로 여러 구간(윈도우)을 생성하여 학습 데이터를 구성하였다. 필터링은 이동평균 기반 방식으로 구현하였으며, 원신호에서 이동평균을 차감하는 detrending을 통해 baseline 변동을 제거하고, 이후 짧은 이동평균 smoothing을 추가 적용하여 고주파 잡음을 완화하였다. 필터링 파라미터는 detrending 윈도우 크기 BASELINE\_MA = 301, smoothing 윈도우 크기 SMOOTH\_MA = 5로 설정하였고, 파일(세그먼트)별 신호 오프셋 및 장기 추세의 영향을 줄여 맥파 형태적 패턴이 보다 일관되게 반영되도록 하였다.

윈도우 구성 파라미터는 윈도우 길이 WIN\_LEN = 300(sample), 이동 간격 HOP = 100으로 설정하였으며, 한 윈도우가 단일 구간 내 맥파의 형태적 특징을 충분히 포함하면서도, 인접 구간 간 중복을 통해 시간적 연속성을 유지하도록 설계하였다. 파일마다 생성되는 윈도우 수 차이로 인해 입력 크기가 달라지는 문제를 방지하기 위해 파일당 윈도우 개수를 N\_WINS\_PER\_FILE = 128로 고정하였다. 즉, 한 파일은 128개의 짧은 구간(각 300 샘플)으로 표현되며, 이를 통해 파일 간 길이 차이가 존재하더라도 모델 입력 차원을 동일하게 유지할 수 있다. 또한, 신호 크기 차이에 따른 영향을 줄이기 위해 Z-score 정규화(USE\_ZSCORE = True)를 적용하였으며, 개인별·세션별로 발생하는 신호 진폭 차이가 분류 과정에서 불필요한 편차로 작용하지 않도록 하였다. 학습 시에는 윈도우 선택을 무작위로 수행하여 데이터 다양성을 확보하였고, 평가 시에는 동일 조건에서 재현 가능하도록 일정 규칙에 따라 윈도우를 선택하였다. 윈도우 개수가 부족한 경우에는 입력 크기 유지를 위해 보정 처리를 적용하였다. 또한, 실험 결과의 재현성을 확보하기 위해 데이터 분할 및 학습 과정 전반에서 고정된 random seed를 사용하였다.

모델 학습은 PyTorch 기반으로 수행하였으며, 데이터 배치는 윈도우 단위가 아닌 파일 단위로 구성하였다. 개별 윈도우의 단일 구간 신호보다 파일 전체에 걸쳐 반복적으로 나타나는 PPG 패턴을 분석 단위로 사용하는 방식이 개인 식별 및 연령대 분류에 보다 적합한 구조이기 때문이다. 한 배치에는 여러 개의 파일이 포함되며, 각 파일은 128개의 윈도우 묶음으로 입력된다. 배치 구성 파라미터는 BATCH\_FILES = 8로 설정하였다. 학습·검증 분할은 클래스 불균형의 영향을 줄이기 위해 scikit-learn의 StratifiedKFold(n\_splits = 4) 기반 교차검증으로 구성하였고, 각 fold에서 파일 단위 라벨 분포가 유지되도록 분할하였다.

분류 모델은 PPG의 시간적 패턴을 효과적으로 반영하기 위해 1차원 합성곱 신경망(1D CNN) 기반으로 설계하였다. 각 파일을 128개의 윈도우로 분할한 뒤, 각 윈도우에 대해 1D CNN 인코더를 적용하여 특징 벡터를 추출하고, 파일에 포함된 다수의 윈도우 특징을 통합해 파일을 대표하는 하나의 특징 표현을 구성한 다음 파일당 하나의 클래스를 예측하는 구조이다. 단일 구간의 신호만으로 판단하기보다, 파일 전체에 걸쳐 반복적으로 나타나는 PPG 패턴을 종합적으로 반영하기 위한 설계이다.

윈도우 특징 추출부는 ResNet 계열의 1D CNN 구조(base\_ch = 32, blocks = (2, 2, 2))를 사용하였으며, 시간 축 방향으로 특징을 단계적으로 확장하면서도, 깊이에 따른 학습 불안정성을 완화하도록 구성하였다. 파일 단위 통합 단계에서는 모든 윈도우를 동일하게 취급하는 단순 평균 방식 대신 attention 기반 통합(pool = "attn")을 적용하여, 파일 내부에서도 분류에 더 기여하는 구간이 강조되도록 하였다.

과적합을 완화하고 모델의 일반화 성능을 높이기 위해 dropout = 0.3을 적용하였으며, 최적화는 Adam 옵티마이저(learning rate LR = 1e-3, weight decay WD = 1e-4)를 사용하였다. 손실함수는 다중 분류 문제에 적합한

CrossEntropyLoss를 사용하였다. 학습은 EPOCHS = 30을 상한으로 진행하되, 검증 성능이 더 이상 개선되지 않을 때는 불필요한 반복 학습을 줄이기 위해 patience = 10의 early stopping을 적용하였다. 성능 평가는 fold별로 accuracy와 macro F1-score를 산출하고, 혼동행렬(confusion matrix)을 함께 확인하여 전체 성능 뿐 아니라 클래스별 오분류 양상까지 해석할 수 있도록 구성하였다.

## **IV. Procedure**

실험 및 분석은 PPG 데이터 수집을 시작으로 데이터 변환과 전처리, 라벨링을 거쳐 학습 데이터를 구성하고, 이를 기반으로 모델 학습 및 결과 분석을 수행하는 순서로 진행되었다.

실험에 앞서 측정 조건에 따른 생체신호 변동을 최소화하기 위해, 모든 측정은 실험자가 의자에 앉은 상태에서 약 2분간 안정(resting) 시간을 가진 후 시작하였다. 측정 직후 발생할 수 있는 자세 변화나 초기 생리적 변동이 PPG 파형에 미치는 영향을 줄이도록 구성하였다. 이후, PPG 측정은 의자에 앉은 정자세를 유지한 상태에서 진행하였으며, 손은 책상 위 동일한 위치에 고정하고 불필요한 움직임을 최대한 제한하였다. 측정 동안에는 휴식 상태를 유지하도록 하였고, 측정 환경은 집 또는 기숙사 등 비교적 조용한 장소에서 수행되었으며, 외부 소음을 최소화하고 실내 온도를 일정하게 유지하였다. 또한, 일중 변동의 영향을 줄이기 위해 매일 저녁 7시부터 11시 사이의 유사한 시간대에 측정을 수행하였다.

PPG 데이터는 손가락 PPG 센서를 이용해 수집하였으며, 각 측정에서는 완전히 움직이지 않은 상태에서 약 5분 30초 동안 연속적으로 PPG 신호를 기록하였다. 이러한 측정을 하루에 5회씩 반복하였고, 동일한 과정을 여러 날에 걸쳐 수행하여 총 15개의 측정 세그먼트를 확보하였다. 각 측정 세그먼트는 이후 분석에서 하나의 파일 단위 데이터로 사용되었다.

임베디드 보드로부터 수집된 PPG 데이터는 텍스트 파일(txt) 형태로 저장되었으며, 이후 분석을 위해 해당 파일들을 CSV 형식으로 변환한 뒤 Google Drive에 업로드하였다. 변환된 CSV 파일은 Google Colaboratory 환경에서 불러와 데이터프레임 형태로 저장하여 이후 전처리 및 모델 학습에 사용하였다. 이 과정에서 신호가 비정상적으로 끊기거나 기록 길이가 현저히 짧은 파일은 분석 대상에서 제외하여 데이터 품질을 유지하였다.

데이터 분석 단계에서는 원시 PPG 시계열에 대해 필터링을 적용하여 측정 과정에서 발생할 수 있는 잡음과 불필요한 고주파 성분을 완화하였다. 이후, 각 파일에 대해 개인 식별 또는 연령대 분류를 위한 라벨링 및 매핑 작업을 수행하였으며, 파일 경로 및 파일명 정보를 기준으로 라벨이 일관되게 부여되도록 구성하였다.

전처리가 완료된 데이터는 개인 식별 및 연령대 분류를 위한 딥러닝 모델 학습에 사용하였다. 개인 식별 실험과 연령대 분류 실험은 동일한 전처리 및 학습 절차를 기반으로 하되, 분류 대상 클래스만 달리하여 각각 독립적으로 수행하였다. 모델 학습 과정에서는 데이터 분할, 학습, 검증이 단계적으로 이루어졌으며, 학습된 모델을 이용해 각 파일 단위에 대한 예측 결과를 도출하였다.

마지막으로, 모델의 분류 성능을 정량적으로 평가하기 위해 정확도(accuracy)와 F1-score를 산출하였고, 혼동행렬을 통해 개인 식별 및 연령대 분류에서의 오분류 양상을 비교 및 분석하였다. 이러한 절차를 통해 단일 PPG 신호를 이용한 개인 식별 및 연령대 분류의 가능성을 단계적으로 검증하였다.

## V. Data/Result

실험에 사용된 데이터는 임베디드 보드를 통해 직접 측정된 PPG 신호로 구성되었으며, 모든 데이터는 파일 단위 분석을 기준으로 정리되었다. 각 파일은 약 5분 30초(330초) 동안 연속적으로 기록된 PPG 시계열로 이루어져 있으며, 총 60개의 파일이 분석에 사용되었다. 모든 파일은 동일한 측정 조건과 신호 길이를 갖도록 통제되었고, 이후 전처리 및 모델 입력 과정에서도 파일 단위가 유지되었다.

연령대 분류 실험에서는 측정 데이터를 20대와 50대 두 그룹으로 구분하여 라벨링 하였으며, 각 그룹당 30개의 파일로 구성된 2-class 분류 문제로 설정하였다. 개인 식별 실험에서는 총 4명의 피험자를 대상으로 각 개인당 15개의 파일을 사용하여 4-class 분류 문제를 구성하였다. 두 실험 모두에서 클래스 간 데이터 수는 균형을 이루도록 구성되었다.




그림 1. 원시 PPG 신호와 이동 평균 기반 전처리 이후 PPG 신호의 비교

원시 PPG 신호는 저주파 baseline drift와 고주파 잡음을 동시에 포함하고 있었으며, 전처리 단계에서 이동 평균 기반 detrending 및 smoothing을 적용하였다. 원시 신호와 전처리 이후 신호의 비교 결과를 그림 1에 제시하였다. 필터링 적용 후에는 장기적인 기준선 변동과 불규칙한 진폭 변동이 감소하였고, 심박에 따른 주기적 맥파 패턴이 보다 안정적으로 나타나는 것을 확인할 수 있었다 (그림 1).

이후, 슬라이딩 윈도우 방식으로 각 파일을 여러 개의 짧은 구간으로 분할하였으며, 파일당 최대 128개의 윈도우만을 사용하여 입력 차원을 고정하였다. 또한 Z-score 정규화를 통해 개인별·세션별 신호 진폭 차이가 분류 기준으로 과도하게 작용하지 않도록 하였다.

모델 학습과 평가는 4-fold StratifiedKFold 교차검증 방식으로 수행되었으며, 각 fold에서 45개의 파일을 훈련 데이터로, 15개의 파일을 테스트 데이터로 사용하였다. 모든 fold에서 클래스 비율이 유지되도록 분할되었으며, fold별 학습과 평가는 서로 독립적으로 진행되었다.




그림 2. 연령대 분류 실험에서 fold별 정확도와 macro F1-score




그림 3. 연령대 분류 실험의 fold별 혼동행렬

연령대 분류 실험 결과, 대부분의 fold에서 안정적인 분류 성능이 확인되었다. 4-fold 교차검증에서의 fold별 정확도와 macro F1-score는 그림 2에 제시하였다. Fold 1, Fold 2, Fold 4에서는 테스트 파일 15개가 모두 정확하게 분류되어 정확도(accuracy)와 macro F1-score가 각각 1.0을 기록하였다. 반면 Fold 3에서는 정확도 0.73, macro F1-score 약 0.70으로 상대적으로 낮은 성능이 관찰되었다 (그림 2).

연령대 분류 실험의 fold별 혼동행렬은 그림 3에 제시하였다. 혼동행렬 분석 결과, Fold 3에서는 50대 파일은 모두 정확히 분류되었으나, 일부 20대 파일이 50대로 오분류되는 양상이 나타났다. 이러한 오분류는 다른 fold에서는 관찰되지 않았으며, fold 간 성능 차이는 개별 파일에 포함된 PPG 파형의 변동성 차이가 반영된 결과로 해석된다(그림 3). 개별 fold 간 성능 차이가 확인되었으나, 전체 4개 fold 평균 기준으로 정확도 0.95, macro F1-score 약 0.95를 기록하여, 단일 PPG 신호만을 이용한 연령대 분류가 해당 데이터 구성 내에서는 비교적 높은 분류 성능을 보이는 경향이 관찰되었다.




그림 4. 개인 식별 실험에서 fold별 정확도와 macro F1-score




그림 5. 개인 식별 실험의 혼동행렬

개인 식별 실험에서는 연령대 분류 실험에 비해 전반적으로 더 우수한 성능이 나타났다. 개인 식별 실험의 fold별 정확도와 macro F1-score는 그림 4에 제시하였다. Fold 1과 Fold 2에서는 모든 테스트 파일이 정확하게 분류되어 정확도와 macro F1-score가 모두 1.0을 기록하였으며, Fold 4에서도 동일한 결과가 확인되었다. Fold 3에서는 특정 피험자(S1)의 일부 파일이 다른 개인으로 오분류되면서 정확도 0.80, macro F1-score 약 0.77로 소폭의 성능 저하가 발생하였다 (그림 4).

개인 식별 실험의 혼동행렬 분석 결과는 그림 5에 제시하였다. 오분류가 발생한 경우에도 혼동은 특정 두 개

인 사이에서만 제한적으로 나타났으며, 파일 단위로 분할된 PPG 신호가 개인 고유의 생리적 특성을 충분히 반영하고 있음을 의미한다(그림 5). 전체 4개 fold 평균 성능은 정확도 약 0.98, macro F1-score 약 0.98로 매우 높은 수준을 유지하였다.

반복 측정된 PPG 신호를 파일 단위로 구성하여 분석한 결과, 개인 식별과 연령대 분류 모두에서 일관된 분류 양상이 확인되었다. 개인 식별의 경우 대부분의 fold에서 높은 정확도와 F1-score가 유지되었으며, 연령대 분류에서는 일부 fold에서 성능 변동이 나타났지만 전반적으로 두 그룹 간 구분 경향은 유지되었다.

## **VI. Discussion**

파일 단위로 분석한 PPG 신호는 개인 식별과 연령대 분류 모두에서 안정적인 분류 성능을 보였다. 특히 개인 식별에서는 대부분의 fold에서 높은 성능이 유지되어, 동일 조건에서 반복 측정된 PPG 파형이 파일 단위 기준으로 개인별 차이를 일정 수준 반영하고 있음을 보여준다. 반면 연령대 분류에서는 fold 간 성능 편차가 상대적으로 크게 나타났으며, 개인 식별에 비해 분류 난이도가 더 높게 관찰되었다.

이러한 차이는 데이터 구조와 라벨 구성 방식과도 밀접하게 연결된다. 개인 식별은 동일 개인으로부터 반복 측정된 파일들이 다수 존재하고, 같은 개인의 파형 특성이 파일 단위에서 비교적 일관되게 유지되는 구조를 갖는다. 반대로 연령대 분류는 각 그룹에 서로 다른 개인이 포함되는 형태로 구성되어, 연령에 따른 생리적 차이와 개인 간 변동성이 동시에 작용한다. 이 과정에서 특정 fold에서 일부 개인의 파형 특성이 다른 연령대의 패턴과 유사하게 나타날 때 오분류가 발생할 수 있으며, 관찰된 성능 변동은 이러한 영향이 반영된 사례로 볼 수 있다. 즉, 연령대 분류 성능은 연령 차이만을 단독으로 반영하기보다는 개인 간 생리적 다양성의 영향을 함께 받는 성격을 가진다.

데이터 규모 또한 중요한 제한 요소로 작용한다. 사용된 데이터는 총 4명의 피험자를 대상으로 구성된 소규모 데이터셋이며, 각 연령대가 2명씩으로 제한되어 있다. 이 구조에서는 연령 라벨이 개인 단위에 종속되는 형태를 보이게 되어, 모델이 연령 자체의 일반적인 특성보다는 특정 개인의 파형 특성을 학습했을 가능성을 완전히 배제하기 어렵다. 연령대 분류에서 높은 성능이 관찰되었더라도, 동일 연령대 내 개인 수가 충분히 확보된 상황에서의 일반화 성능을 직접적으로 의미하지는 않는다.

PPG 신호로 개인을 구별할 수 있는 이유에 대해서도 해석이 필요하다. 혈관 구조, 말초 혈류 특성, 심박 변동성 등 개인별 생리적 차이가 파형의 형태적 특징으로 반영될 수 있으며, 개인 식별 성능으로 연결될 가능성이 있다. 다만, 3일간 반복 측정이라는 실험 설정에서 날짜-세션별 미세한 환경 차이(손가락 압력, 센서 부착 상태, 주변 온도/혈류 변화, 컨디션 변화 등)가 완전히 통제되기 어렵다. 따라서, 모델이 개인 고유 특성뿐 아니라 세션 특성까지 함께 학습했을 가능성도 고려할 필요가 있다. 또한, 파일 단위의 교차검증 분할이 날짜 단위로 완전히 분리되었는지 불분명한 경우, 동일 날짜의 신호 특성이 학습과 평가에 동시에 포함되었을 가능성도 남는다. 결과적으로 모델이 사람 자체를 구분한 것인지, 반복 측정된 특정 조건의 신호를 구분한 것인지에 대해서는 추가적인 검증이 요구된다.

연령대 분류 성능이 개인 식별에 비해 낮거나 변동이 큰 점은, 단순한 생리적 특성만으로 설명하기 어려운 부분이 있다. 일반적으로 연령 증가에 따라 혈관 탄성 감소나 맥파 변화가 나타날 수 있으나, 본 데이터에서 실제 측정된 PPG 파형은 이러한 차이가 단일 지표로 뚜렷하게 구분되는 양상을 보이지 않았다. 개인별 기저 특성, 생활 습관, 건강 상태 등 다양한 요인이 연령의 효과를 상쇄하거나 왜곡할 가능성도 존재한다. 또한, Z-score

정규화를 적용한 설계는 진폭 차이에 과도하게 의존하는 분류를 억제하는 방향으로 작동하므로, 모델이 단순한 크기(높고 낮음)보다는 형태적 패턴(파형 모양, 주기성, 구간별 변동)에 더 의존하게 된다. 이는 연령대 분류가 '연령대의 공통 패턴을 얼마나 일반화할 수 있는가'라는 문제로 남게 되고, 소수 피험자 구성에서는 난이도가 더 크게 드러날 수 있다.

개선 방향은 데이터 구성과 평가 방식에서 정리할 수 있다. 먼저 연령대 분류의 타당성을 분명히 하려면, 같은 연령대 안에서도 서로 다른 사람을 더 많이 포함하도록 피험자 수를 늘리는 것이 중요하다. 각 연령대에 포함된 피험자 수가 적을수록 모델이 나이의 공통 특징을 학습하기보다 특정 개인의 특징을 외워 맞춘 것처럼 보일 가능성이 커진다. 이 위험을 줄이기 위해 연령대 분류 평가는 가능한 범위에서 학습과 테스트에 서로 다른 사람만 들어가도록 구성하는 편이 설득력을 높인다. 개인 식별의 경우에도 시간에 따른 변화에 강한지 확인하는 과정이 필요하다. 예를 들어, 특정 날짜(또는 세션)를 통째로 테스트로 두고 나머지 날짜로 학습하는 방식을 적용하면, 모델이 "사람"의 특징을 잡는지, 혹은 "그날의 컨디션"에 더 의존하는지 명확하게 판단할 수 있다. 측정 과정에서는 손가락 압력, 센서 위치, 움직임 같은 요인을 더 엄격히 통제하고 신호 품질이 떨어지는 구간을 걸러내는 기준을 두면, fold 별 성능 변동을 줄이는 데도 도움이 된다.

모델 측면에서는 현재 사용한 1D CNN과 attention 기반 통합이 좋은 결과를 보였지만, 비교 관점에서 긴 시간 흐름의 의존성을 더 직접적으로 다루는 모델(RNN 계열 혹은 Transformer 계열)도 후보가 될 수 있다. 또한, PPG는 파형의 모양뿐 아니라 주기성이나 리듬 같은 요소가 중요할 수 있으므로, 주파수 영역 특징이나 파형 기반의 명시적 특징을 함께 넣어 성능과 안정성을 비교하는 방식도 검토할 만하다. 더불어 결과의 설득력을 높이기 위해서는 "왜 그렇게 판단했는가"를 보여줄 근거가 필요하다. attention이 어떤 구간에 더 크게 집중했는지 (가중치 분포)를 분석하면, 모델이 실제로 어떤 부분을 근거로 분류했는지를 더 분명하게 설명할 수 있다.

종합하면, 파일 단위로 분석한 PPG는 개인 식별과 연령대 분류 모두에서 전반적으로 안정적인 성능을 보였으며, 특히 개인 식별은 대부분의 fold에서 높은 성능이 유지되어 개인별로 구분 가능한 파형 특성이 존재함을 의미한다. 연령대 분류는 fold 간 편차가 더 컸고, 연령의 효과뿐 아니라 개인차와 라벨 구조의 영향이 함께 반영된 결과로 해석될 수 있다. 다만, 피험자 수가 매우 적어 일반화에는 제한이 남으며, 피험자 다양성 확대와 사람이나 날짜 단위 분리 평가를 통해 추가 검증이 요구된다.

## **VII. Conclusion**

손가락에서 측정한 PPG 파형은 파일 단위로 누적하여 분석했을 때, 개인 간 차이를 구분하는 데 활용 가능한 특징을 일정 수준 포함하고 있었다. 짧은 구간 하나에 의존하기보다 일정 시간 동안 반복적으로 나타나는 파형 패턴을 하나의 판단 단위로 구성한 방식은 순간적인 잡음이나 변동의 영향을 줄이고, 개인별로 반복되는 신호 특성을 보다 안정적으로 반영하는 방향으로 작동했다.

연령대 분류에서도 일부 조건에서는 비교적 높은 성능이 관찰되었으나, 개인 식별에 비해 결과의 변동성이 더 크게 관찰되었다. 연령대 라벨 안에 서로 다른 개인이 포함되면서 연령에 따른 변화와 개인차가 함께 작용했고, 일부 경우에는 특정 개인의 파형 특성이 다른 연령대의 패턴과 유사하게 나타날 여지도 존재했다. 피험자 수가 제한된 구성에서는 연령의 공통 특성이 충분히 학습되었다고 보기보다, 개인별 특성이 분류에 더 크게 작용했을 가능성을 배제하기 어렵다. 또한, 날짜나 세션에 따른 특성이 학습과 평가 과정에 함께 반영되었을 가능성도 고려할 필요가 있다.



PPG 단일 신호 기반 분류는 웨어러블 환경에서 간편한 개인 인증으로 확장될 가능성을 보여준다. 연령대 분류 역시 혈관 노화와 연관된 지표로 발전할 여지가 있지만, 동일 연령대 내 다양한 개인을 포함한 구성과 사람 단위 또는 날짜 단위로 분리된 평가를 통해 해석의 신뢰도를 높일 필요가 있다. 측정 과정의 압력, 센서 부착 상태, 환경 요인을 더 엄격히 관리하고, 모델이 어떤 구간을 근거로 판단했는지 함께 살펴본다면 결과에 대한 설명력도 한층 강화될 것이다.